

Análise Espacial da Criminalidade no Brasil: uma proposta de integração de dados públicos para identificação de padrões territoriais

Cintia Nunes

Curso de Ciência da Computação – Universidade Federal da Fronteira Sul (UFFS), Campus Chapecó

Disciplina de Planejamento e Gestão de Projetos – Professor Fabrício Herpich

Chapecó, agosto de 2026

1. Introdução

A criminalidade é um dos temas mais discutidos no Brasil, seja nas conversas do dia a dia, seja nos noticiários, seja nas políticas públicas de segurança. Ainda assim, mesmo sendo um assunto tão presente, boa parte da população costuma enxergar a criminalidade apenas por meio de números soltos: total de roubos em tal estado, aumento de homicídios em tal ano. Esses números, isolados, dizem pouco. Eles não mostram onde o problema está concentrado, se existe uma relação entre regiões vizinhas, nem se o que parece um aumento é, na verdade, reflexo do crescimento populacional daquela área.

Nos últimos anos, órgãos como o Ministério da Justiça e Segurança Pública, por meio do Sinesp, e institutos como o IBGE passaram a disponibilizar publicamente conjuntos de dados cada vez mais completos sobre ocorrências criminais, população e território. Esse movimento de abertura de dados é uma oportunidade importante, mas também traz um desafio: dados abertos não são, por si só, dados compreensíveis. É preciso tratar, cruzar e, principalmente, dar contexto espacial a essas informações para que elas realmente ajudem a entender o fenômeno da criminalidade.

2. Problema

O problema que motiva este trabalho pode ser resumido em uma pergunta: como dados públicos e técnicas de análise espacial podem ser utilizados para identificar e visualizar padrões de criminalidade entre diferentes regiões do Brasil? Essa pergunta, simples na aparência, esconde uma série de dificuldades práticas que só ficaram claras conforme fomos avançando no levantamento dos dados.

A primeira dificuldade é a heterogeneidade das fontes. O Sinesp VDE reúne informações enviadas pelos gestores estaduais de segurança pública, e cada estado tem sua própria forma de registrar e consolidar as ocorrências. Isso significa que comparar diretamente

o número de ocorrências entre dois estados pode levar a conclusões erradas, já que a metodologia de contagem nem sempre é idêntica. A própria base reconhece essa limitação em suas notas metodológicas, o que reforça a necessidade de cautela na hora de interpretar os números.

A segunda dificuldade está relacionada à unidade de contagem dos indicadores: alguns são contabilizados por vítima, outros por ocorrência. No caso de um indicador como homicídio, por exemplo, uma mesma ocorrência pode envolver mais de uma vítima, o que altera significativamente o total apresentado dependendo de qual critério é utilizado. Sem tratar esse detalhe, uma análise pode acabar comparando coisas que não são exatamente comparáveis.

Há ainda um terceiro problema, talvez o mais intuitivo: comparar estados ou municípios apenas pelo total absoluto de ocorrências favorece, naturalmente, as regiões mais populosas. São Paulo tende a apresentar números maiores do que Roraima simplesmente porque tem muito mais habitantes, e não necessariamente porque é mais violento. Sem uma padronização, como a taxa por 100 mil habitantes, essa distorção compromete qualquer tentativa séria de comparação regional.

Por fim, existe um problema de acessibilidade. Mesmo quando os dados estão disponíveis e corretamente tratados, eles costumam ficar restritos a planilhas, notebooks ou relatórios técnicos, pouco acessíveis para gestores públicos, jornalistas ou pesquisadores que não têm familiaridade com programação. Esse conjunto de dificuldades — heterogeneidade metodológica, diferença entre unidades de contagem, ausência de padronização populacional e baixa acessibilidade, é o que este projeto se propõe a enfrentar.

3. Objetivos e Justificativa

O objetivo geral do projeto é planejar e desenvolver uma solução capaz de organizar, analisar e apresentar espacialmente dados públicos de criminalidade no Brasil, integrando diferentes fontes oficiais em uma base coerente e comparável, e disponibilizando essa análise, futuramente, por meio de uma aplicação web interativa e de fácil uso.

De forma mais específica, o projeto busca:

- (i) levantar e reunir dados de criminalidade de diferentes fontes nacionais, com destaque para o Sinesp VDE, o IBGE, o Atlas da Violência e o SIM/DATASUS;

- (ii) (ii) padronizar e harmonizar essas bases, que possuem formatos e granularidades distintas;
- (iii) (iii) calcular taxas por 100 mil habitantes que permitam comparar unidades da federação com portes populacionais muito diferentes;
- (iv) (iv) construir mapas temáticos e mapas interativos que revelem a distribuição espacial da criminalidade;
- (v) (v) aplicar, em etapas futuras, técnicas de autocorrelação espacial, como o Índice de Moran Global e o LISA, para identificar agrupamentos (clusters) de alta ou baixa criminalidade; e
- (vi) (vi) explorar, também como continuidade, o uso de aprendizado de máquina para estimar níveis de risco por região.

A justificativa deste trabalho é de caráter social e prático: entender onde a criminalidade se concentra e como ela se relaciona espacialmente entre regiões vizinhas pode subsidiar decisões de política pública mais informadas, além de facilitar o trabalho de pesquisadores e jornalistas de dados que hoje precisam lidar manualmente com bases dispersas e pouco amigáveis.

4. Fundamentação Teórica

A fundamentação teórica deste trabalho baseia-se no conceito da análise espacial de dados, que consiste em estudar fenômenos considerando não apenas o seu valor numérico, mas também sua localização geográfica e a relação entre essa localização e a de ocorrências vizinhas. No caso da criminalidade, isso quer dizer ir além de quantos casos aconteceram em determinado estado, mas onde, dentro do território, esses casos se concentram, e se existe alguma relação entre a criminalidade de um lugar e a dos lugares ao redor.

Outro pilar teórico é o do geoprocessamento, ou seja, o conjunto de técnicas que permite manipular, integrar e visualizar dados georreferenciados. No projeto, essa etapa é viabilizada por bibliotecas como o GeoPandas, que possibilitam cruzar tabelas de dados criminais com arquivos de malha territorial, como as malhas digitais de estados e municípios disponibilizadas pelo IBGE, a partir dessa integração, gerar mapas temáticos capazes de mostrar visualmente onde a criminalidade é mais intensa.

Também é importante mencionar o conceito de taxa padronizada por população, amplamente utilizado em estudos de saúde pública e segurança. Comparar apenas totais absolutos de ocorrências entre regiões com populações muito diferentes distorce a análise, já que regiões mais populosas tendem a apresentar números maiores mesmo quando, proporcionalmente, são menos violentas. A taxa por 100 mil habitantes resolve, ao menos parcialmente, esse problema, permitindo comparações mais justas entre unidades da federação de portes distintos.

Por fim, o projeto se apoia na prática de Análise Exploratória de Dados (EDA), etapa em que se busca conhecer a estrutura, a qualidade e as particularidades de uma base antes de qualquer modelagem mais sofisticada. É na EDA que se percebem, por exemplo, campos incompletos, indicadores contabilizados de formas diferentes, ou anos com cobertura incompleta de determinados estados, problemas que, se ignorados, comprometeriam qualquer análise posterior.

5. Trabalhos Relacionados

Existem, no Brasil, iniciativas que já tratam da de maneira organizada e que serviram de referência e de inspiração durante o levantamento inicial. O Atlas da Violência, produzido em parceria entre o Ipea e o Fórum Brasileiro de Segurança Pública, é provavelmente o exemplo mais conhecido: trata-se de um relatório periódico que reúne indicadores de violência, especialmente homicídios, discutindo também as desigualdades territoriais do fenômeno e a qualidade dos dados disponíveis no país. Esse tipo de publicação mostra como é possível transformar dados brutos de segurança pública em análises que realmente dialogam com a sociedade.

O próprio Sinesp, por meio do seu painel público de estatísticas, também representa um esforço de disponibilizar e visualizar dados de segurança de forma mais acessível, ainda que de maneira mais tabular e menos voltada à análise espacial. Já o SIM/DATASUS, mantido pelo Ministério da Saúde, oferece uma perspectiva complementar e bastante utilizada em estudos nacionais sobre homicídios, já que registra óbitos por causas externas e agressões a partir de declarações de óbito, portanto, com origem e metodologia diferentes das bases policiais, mas que frequentemente é usada para validar ou comparar os números de segurança pública.

No campo acadêmico, é bastante comum encontrar trabalhos que aplicam técnicas de estatística espacial, como o próprio Índice de Moran e a estatística LISA, ao estudo da criminalidade em cidades ou regiões específicas do Brasil, geralmente utilizando ferramentas como GeoDa ou bibliotecas Python voltadas à análise espacial, como o PySAL. A criminalidade raramente se distribui de forma homogênea pelo espaço, tendendo a formar concentrações que só ficam evidentes quando se olha para o dado de forma espacial e não apenas tabular. É por esse motivo que este projeto busca contribuir, propondo uma integração entre as fontes de segurança pública, demografia e saúde, em apenas uma única aplicação de exploração espacial de fácil acesso.

6. Metodologia — visão geral

O projeto vem sendo conduzido de forma iterativa, organizado em sprints, seguindo uma lógica próxima da metodologia ágil e inspirada, em seus fundamentos, na Design Science Research Methodology, já que o produto final esperado é uma solução prática, uma aplicação de análise espacial, construída e avaliada ao longo de ciclos sucessivos de planejamento, desenvolvimento e revisão.

Na Sprint 0, o trabalho concentrou-se na definição do escopo do projeto, na elaboração do Business Model Canvas e na escrita das primeiras histórias de usuário, além da estruturação do repositório no GitHub, onde código, dados e o próprio artigo científico passaram a ser versionados. Essa etapa, embora não envolva ainda manipulação de dados propriamente dita, foi fundamental para alinhar expectativas e organizar o backlog de funcionalidades a serem desenvolvidas nas sprints seguintes.

Na Sprint 1, o foco passou a ser efetivamente os dados. A fonte principal utilizada foi o Sinesp VDE, cujas planilhas anuais, de 2015 a 2026, trazem informações sobre unidade da federação, município, tipo de evento, data de referência, totais e abrangência da ocorrência. Nessa etapa, algumas decisões metodológicas precisaram ser tomadas: o campo evento passou a ser tratado como o indicador criminal de interesse; a data de referência foi utilizada para extrair o ano e o mês de cada registro; e, para lidar com a diferença entre contagem por vítima e por ocorrência, o campo `total_vitima` foi priorizado quando preenchido, recorrendo-se ao campo `total` como alternativa nos demais casos.

Para viabilizar a comparação proporcional entre estados, a população residente estimada por unidade da federação foi obtida junto ao SIDRA/IBGE, permitindo o cálculo da taxa de ocorrências por 100 mil habitantes. Já a dimensão espacial da análise foi construída a partir da malha territorial digital das unidades da federação disponibilizada pelo IBGE, em sua versão de 2024, integrada aos dados criminais por meio da biblioteca GeoPandas, o que possibilitou a geração de mapas temáticos e, em uma etapa posterior, de um mapa interativo com detalhamento por estado.

Ao longo dessa análise exploratória, também foram identificados possíveis pontos fora do padrão a partir do intervalo interquartil, uma forma simples e amplamente utilizada de sinalizar valores que se destacam significativamente do restante da distribuição, o que, em dados de criminalidade, pode indicar tanto eventos atípicos quanto possíveis inconsistências no registro.

As próximas etapas do projeto, já mapeadas no backlog, incluem a aplicação de testes de autocorrelação espacial (Moran Global e LISA) para identificar clusters de criminalidade, a exploração de modelos de aprendizado de máquina para estimativa de risco por região e, por fim, a publicação de toda essa análise em uma aplicação web construída com Streamlit, hospedada de forma gratuita, para que o resultado do projeto não fique restrito a um notebook técnico, mas possa ser efetivamente consultado por gestores públicos, pesquisadores e demais interessados no tema. A Sprint 2, detalhada na Seção 7 a seguir, deu continuidade a esse trabalho, avançando da análise exploratória para a construção de um modelo preditivo baseline de estimativa de risco.

As próximas etapas do projeto, já mapeadas no backlog, incluem a aplicação de testes de autocorrelação espacial (Moran Global e LISA) para identificar clusters de criminalidade, o refinamento do modelo de aprendizado de máquina com validação cruzada temporal e ajuste de hiperparâmetros e, por fim, a publicação de toda essa análise em uma aplicação web construída com Streamlit, hospedada de forma gratuita, para que o resultado do projeto não fique restrito a um notebook técnico, mas possa ser efetivamente consultado por gestores públicos, pesquisadores e demais interessados no tema.

7. MVP Analítico

7.1 Enquadramento na Design Science Research Methodology

Seguindo o que já vem sendo desenvolvido desde a Sprint 0, esta etapa do projeto está relacionada à fase de Design e Desenvolvimento da metodologia DSRM. Depois da organização e da análise dos dados realizadas na Sprint 1, o próximo passo foi começar a desenvolver um modelo inicial de previsão, com o objetivo de estimar o nível de risco de criminalidade por Unidade da Federação e por ano.

Para isso, o desenvolvimento foi dividido em algumas etapas. Primeiro, foi necessário definir com mais clareza qual problema o modelo deveria resolver e qual seria a unidade utilizada na análise. Depois disso, os dados passaram por uma etapa de preparação, na qual foram organizados e ajustados para que pudessem ser utilizados no treinamento do modelo.

Também foi definida a variável que o modelo deveria prever e realizada a separação dos dados em conjuntos de treino e teste. A partir disso, alguns modelos diferentes foram treinados e comparados, buscando identificar qual deles apresentava um resultado mais adequado para servir como modelo inicial, ou baseline.

Após essa comparação, o modelo selecionado foi avaliado e salvo para ser utilizado nas próximas etapas do projeto. Mesmo sendo uma primeira versão, ele já permite entender melhor o funcionamento da etapa de previsão e identificar pontos que ainda podem ser melhorados.

7.2 Dados e unidade de análise

A base de dados utilizada nesta etapa foi construída a partir do resumo gerado na Sprint 1, utilizando dados do Sinesp VDE entre os anos de 2015 e 2026. Nessa base, já haviam sido realizados alguns tratamentos, como a padronização dos campos `total_vitima` e `total`, além da exclusão dos anos que não possuíam todos os meses com dados disponíveis.

Nesta etapa, a forma de organizar os dados também foi modificada em relação à análise exploratória realizada anteriormente. Em vez de analisar apenas um ano, um indicador e uma Unidade da Federação por vez, foi criado um conjunto de dados organizado por UF e ano.

Dessa forma, cada linha representa um estado em um determinado ano, enquanto as colunas apresentam os totais anuais dos diferentes indicadores de criminalidade registrados pelo Sinesp VDE.

Essa reorganização dos dados permite acompanhar as informações ao longo dos anos e utilizar diferentes indicadores ao mesmo tempo. Com isso, a base passa a ter várias observações para cada estado e ano, tornando possível o treinamento de modelos de Machine Learning para identificar padrões e realizar estimativas a partir dos dados disponíveis.

7.3 Pré-processamento e engenharia de atributos

A partir do painel de dados, foram criados três grupos principais de atributos para serem utilizados no modelo.

O primeiro grupo é formado pelos dados do próprio ano analisado. Foram utilizados os totais anuais dos diferentes indicadores de criminalidade do Sinesp VDE, com exceção do indicador escolhido como alvo. Também foram incluídos o total geral de ocorrências e a taxa geral por 100 mil habitantes. Essas informações ajudam a representar o cenário da criminalidade de cada estado em determinado ano.

O segundo grupo corresponde aos dados de população. As informações foram obtidas no SIDRA/IBGE, utilizando a Tabela 6579 e a variável 9324. Diferente da Sprint 1, em que a população era consultada para um ano específico, nesta etapa foram considerados todos os anos presentes na base. Isso permitiu calcular as taxas por 100 mil habitantes de forma padronizada ao longo de toda a série histórica.

O terceiro grupo é formado por informações relacionadas ao comportamento dos dados ao longo do tempo. Para cada Unidade da Federação, foi considerada a taxa do indicador-alvo registrada no ano anterior, chamada de `taxa_alvo_100k_lag1`, além da variação percentual em relação ao ano anterior. Esses dados ajudam o modelo a identificar tendências e mudanças na criminalidade ao longo dos anos, evitando que cada período seja analisado de forma totalmente isolada.

Antes do treinamento, os dados também passaram por uma etapa de preparação utilizando recursos da biblioteca scikit-learn. Foi criado um pipeline para organizar automaticamente esse processo. Os valores ausentes foram preenchidos utilizando a mediana dos dados, por meio do SimpleImputer, e as variáveis foram padronizadas utilizando o StandardScaler.

O uso desse pipeline torna o processo mais organizado e também evita que informações do conjunto de teste sejam utilizadas durante o treinamento. Dessa forma, valores como mediana, média e desvio-padrão são calculados apenas com os dados de treino e, posteriormente, aplicados aos dados de teste. Isso contribui para uma avaliação mais confiável do modelo.

7.4 Definição da variável-alvo

Nesta etapa, o problema foi tratado como uma tarefa de classificação em três níveis de risco: Baixo, Médio e Alto. Em vez de prever diretamente a taxa de criminalidade por 100 mil habitantes, o modelo busca identificar em qual dessas categorias cada estado e ano se encontra.

Essa escolha foi feita principalmente para facilitar a interpretação dos resultados. Para gestores públicos e futuros usuários da aplicação, categorias de risco tendem a ser mais fáceis de compreender do que valores numéricos isolados. Além disso, a divisão em classes ajuda a diminuir o impacto de pequenas variações nas taxas anuais, que podem ocorrer por diferenças na forma como os dados são registrados entre os estados.

As categorias foram definidas a partir da distribuição das taxas do indicador escolhido como alvo. Os valores foram divididos em três grupos de tamanho semelhante, chamados de tercís. Dessa forma, as menores taxas foram classificadas como risco Baixo, as intermediárias como Médio e as maiores como Alto.

Essa forma de classificação foi utilizada como uma solução inicial para o desenvolvimento do MVP, já que não existe, neste projeto, um limite oficial definido por algum órgão público para determinar quando uma taxa deve ser considerada baixa, média ou

alta. Por esse motivo, essa escolha também é considerada uma limitação do trabalho. Os tercis não representam uma classificação oficial de risco em segurança pública, mas servem como uma forma simples, reproduzível e adequada para esta primeira versão do modelo.

7.5 Separação treino/teste

A separação dos dados entre treino e teste foi realizada considerando a ordem dos anos. Os anos mais recentes e completos da base foram utilizados para testar o modelo, enquanto os anos anteriores foram utilizados no treinamento.

Essa escolha foi feita porque o objetivo do modelo é utilizar informações do passado para estimar o risco em períodos futuros. Por isso, não seria adequado misturar os anos de forma aleatória, pois dados de anos mais recentes poderiam acabar sendo utilizados durante o treinamento.

Esse tipo de situação poderia fazer com que o modelo apresentasse resultados melhores do que realmente teria ao trabalhar com dados futuros. Ao respeitar a ordem cronológica, a avaliação fica mais próxima de uma situação real de uso, em que o modelo aprende com os anos anteriores e depois é testado com dados que ainda não foram vistos durante o treinamento.

7.6 Modelos comparados

Para comparar o desempenho do modelo, foram treinados três algoritmos utilizando o mesmo processo de preparação dos dados.

O primeiro foi o Dummy Classifier, utilizado como uma referência básica. Ele não aprende relações entre as variáveis, apenas gera previsões com base na proporção das classes existentes nos dados de treino. Dessa forma, ele serve como um ponto de comparação: os outros modelos precisam apresentar resultados melhores para serem considerados realmente úteis.

O segundo modelo foi a Regressão Logística, que é um modelo mais simples e de fácil interpretação. Ela foi utilizada como uma segunda referência antes da aplicação de modelos mais complexos.

Por fim, foi utilizado o Random Forest, um modelo formado por várias árvores de decisão. Ele consegue identificar relações mais complexas entre os diferentes indicadores da base, inclusive quando essas relações não são lineares. Por esse motivo, é bastante utilizado em problemas de classificação com dados organizados em tabelas.

A comparação entre esses três modelos permite avaliar se o uso de técnicas mais complexas realmente melhora os resultados em relação às abordagens mais simples.

7.7 Métricas de avaliação

Para avaliar o desempenho dos modelos, foram utilizadas duas métricas principais: taxa de acertos e F1-macro.

A taxa de acertos mostra, de forma geral, quantas previsões o modelo acertou. Por exemplo, se o modelo realizou 100 previsões e acertou 80 delas, sua taxa de acertos seria de 80%. Essa métrica é simples de interpretar, por isso foi mantida como uma das formas de avaliação.

Já o F1-macro foi utilizado como principal critério para comparar os modelos. Diferente da taxa de acertos, ele avalia o desempenho do modelo em cada uma das classes de risco, Baixo, Médio e Alto, separadamente. Depois, é calculada uma média entre os resultados das três classes. Dessa forma, todas recebem a mesma importância, mesmo que alguma apareça com mais frequência na base de dados.

Isso é importante porque, ao separar os dados por ano, pode acontecer de uma determinada classe aparecer mais vezes no conjunto de treino ou de teste. Nesse caso, somente a taxa de acertos poderia dar a impressão de que o modelo está tendo um bom desempenho, mesmo que ele tenha dificuldade para identificar uma das classes. O F1-macro ajuda a evitar esse problema.

Também foi utilizada a matriz de confusão para entender melhor onde o modelo acertou e onde cometeu erros. Ela permite observar, por exemplo, quando uma situação de risco Alto foi classificada corretamente ou confundida com as classes Médio ou Baixo.

No Random Forest, também foi analisado quais dados tiveram maior influência nas decisões do modelo. Com isso, foi possível observar se as previsões estavam sendo mais influenciadas pelos diferentes tipos de ocorrências criminais, pela população do estado ou pelo histórico do próprio indicador analisado.

Essas formas de avaliação ajudam não apenas a escolher o modelo com melhor resultado, mas também a compreender melhor como ele realiza suas classificações e quais pontos ainda podem ser melhorados.

7.8 Resultado exportado

O pipeline completo do modelo que apresentou o melhor desempenho foi salvo utilizando a biblioteca joblib. Nesse arquivo foram incluídos tanto o pré-processamento dos dados quanto o modelo já treinado.

Também foram salvas algumas informações importantes sobre o experimento, como o indicador utilizado como alvo, os atributos considerados, os anos usados para treino e teste e os limites definidos para separar as classes de risco em Baixo, Médio e Alto.

O modelo foi versionado no repositório do projeto no GitHub, juntamente com a tabela de comparação das métricas obtidas por cada modelo. Dessa forma, essa etapa pode ser reproduzida ou reutilizada nas próximas sprints sem a necessidade de realizar todo o treinamento novamente.