

Análise Espacial da Criminalidade no Brasil: uma proposta de integração de dados públicos para identificação de padrões territoriais

Cintia Nunes

Curso de Ciência da Computação – Universidade Federal da Fronteira Sul (UFFS), Campus Chapecó

Disciplina de Planejamento e Gestão de Projetos – Professor Fabrício Herpich

Chapecó, agosto de 2026

1. Introdução

A criminalidade é um dos temas mais discutidos no Brasil, seja nas conversas do dia a dia, seja nos noticiários, seja nas políticas públicas de segurança. Ainda assim, mesmo sendo um assunto tão presente, boa parte da população costuma enxergar a criminalidade apenas por meio de números soltos: total de roubos em tal estado, aumento de homicídios em tal ano. Esses números, isolados, dizem pouco. Eles não mostram onde o problema está concentrado, se existe uma relação entre regiões vizinhas, nem se o que parece um aumento é, na verdade, reflexo do crescimento populacional daquela área.

Nos últimos anos, órgãos como o Ministério da Justiça e Segurança Pública, por meio do Sinesp, e institutos como o IBGE passaram a disponibilizar publicamente conjuntos de dados cada vez mais completos sobre ocorrências criminais, população e território. Esse movimento de abertura de dados é uma oportunidade importante, mas também traz um desafio: dados abertos não são, por si só, dados compreensíveis. É preciso tratar, cruzar e, principalmente, dar contexto espacial a essas informações para que elas realmente ajudem a entender o fenômeno da criminalidade.

2. Problema

O problema que motiva este trabalho pode ser resumido em uma pergunta: como dados públicos e técnicas de análise espacial podem ser utilizados para identificar e visualizar padrões de criminalidade entre diferentes regiões do Brasil? Essa pergunta, simples na aparência, esconde uma série de dificuldades práticas que só ficaram claras conforme fomos avançando no levantamento dos dados.

A primeira dificuldade é a heterogeneidade das fontes. O Sinesp VDE reúne informações enviadas pelos gestores estaduais de segurança pública, e cada estado tem sua própria forma de registrar e consolidar as ocorrências. Isso significa que comparar diretamente

o número de ocorrências entre dois estados pode levar a conclusões erradas, já que a metodologia de contagem nem sempre é idêntica. A própria base reconhece essa limitação em suas notas metodológicas, o que reforça a necessidade de cautela na hora de interpretar os números.

A segunda dificuldade está relacionada à unidade de contagem dos indicadores: alguns são contabilizados por vítima, outros por ocorrência. No caso de um indicador como homicídio, por exemplo, uma mesma ocorrência pode envolver mais de uma vítima, o que altera significativamente o total apresentado dependendo de qual critério é utilizado. Sem tratar esse detalhe, uma análise pode acabar comparando coisas que não são exatamente comparáveis.

Há ainda um terceiro problema, talvez o mais intuitivo: comparar estados ou municípios apenas pelo total absoluto de ocorrências favorece, naturalmente, as regiões mais populosas. São Paulo tende a apresentar números maiores do que Roraima simplesmente porque tem muito mais habitantes, e não necessariamente porque é mais violento. Sem uma padronização, como a taxa por 100 mil habitantes, essa distorção compromete qualquer tentativa séria de comparação regional.

Por fim, existe um problema de acessibilidade. Mesmo quando os dados estão disponíveis e corretamente tratados, eles costumam ficar restritos a planilhas, notebooks ou relatórios técnicos, pouco acessíveis para gestores públicos, jornalistas ou pesquisadores que não têm familiaridade com programação. Esse conjunto de dificuldades — heterogeneidade metodológica, diferença entre unidades de contagem, ausência de padronização populacional e baixa acessibilidade, é o que este projeto se propõe a enfrentar.

3. Objetivos e Justificativa

O objetivo geral do projeto é planejar e desenvolver uma solução capaz de organizar, analisar e apresentar espacialmente dados públicos de criminalidade no Brasil, integrando diferentes fontes oficiais em uma base coerente e comparável, e disponibilizando essa análise, futuramente, por meio de uma aplicação web interativa e de fácil uso.

De forma mais específica, o projeto busca:

- (i) levantar e reunir dados de criminalidade de diferentes fontes nacionais, com destaque para o Sinesp VDE, o IBGE, o Atlas da Violência e o SIM/DATASUS;

- (ii) (ii) padronizar e harmonizar essas bases, que possuem formatos e granularidades distintas;
- (iii) (iii) calcular taxas por 100 mil habitantes que permitam comparar unidades da federação com portes populacionais muito diferentes;
- (iv) (iv) construir mapas temáticos e mapas interativos que revelem a distribuição espacial da criminalidade;
- (v) (v) aplicar, em etapas futuras, técnicas de autocorrelação espacial, como o Índice de Moran Global e o LISA, para identificar agrupamentos (clusters) de alta ou baixa criminalidade; e
- (vi) (vi) explorar, também como continuidade, o uso de aprendizado de máquina para estimar níveis de risco por região.

A justificativa deste trabalho é de caráter social e prático: entender onde a criminalidade se concentra e como ela se relaciona espacialmente entre regiões vizinhas pode subsidiar decisões de política pública mais informadas, além de facilitar o trabalho de pesquisadores e jornalistas de dados que hoje precisam lidar manualmente com bases dispersas e pouco amigáveis.

4. Fundamentação Teórica

A fundamentação teórica deste trabalho baseia-se no conceito da análise espacial de dados, que consiste em estudar fenômenos considerando não apenas o seu valor numérico, mas também sua localização geográfica e a relação entre essa localização e a de ocorrências vizinhas. No caso da criminalidade, isso quer dizer ir além de quantos casos aconteceram em determinado estado, mas onde, dentro do território, esses casos se concentram, e se existe alguma relação entre a criminalidade de um lugar e a dos lugares ao redor.

Outro pilar teórico é o do geoprocessamento, ou seja, o conjunto de técnicas que permite manipular, integrar e visualizar dados georreferenciados. No projeto, essa etapa é viabilizada por bibliotecas como o GeoPandas, que possibilitam cruzar tabelas de dados criminais com arquivos de malha territorial, como as malhas digitais de estados e municípios disponibilizadas pelo IBGE, a partir dessa integração, gerar mapas temáticos capazes de mostrar visualmente onde a criminalidade é mais intensa.

Também é importante mencionar o conceito de taxa padronizada por população, amplamente utilizado em estudos de saúde pública e segurança. Comparar apenas totais absolutos de ocorrências entre regiões com populações muito diferentes distorce a análise, já que regiões mais populosas tendem a apresentar números maiores mesmo quando, proporcionalmente, são menos violentas. A taxa por 100 mil habitantes resolve, ao menos parcialmente, esse problema, permitindo comparações mais justas entre unidades da federação de portes distintos.

Por fim, o projeto se apoia na prática de Análise Exploratória de Dados (EDA), etapa em que se busca conhecer a estrutura, a qualidade e as particularidades de uma base antes de qualquer modelagem mais sofisticada. É na EDA que se percebem, por exemplo, campos incompletos, indicadores contabilizados de formas diferentes, ou anos com cobertura incompleta de determinados estados, problemas que, se ignorados, comprometeriam qualquer análise posterior.

5. Trabalhos Relacionados

Existem, no Brasil, iniciativas que já tratam da de maneira organizada e que serviram de referência e de inspiração durante o levantamento inicial. O Atlas da Violência, produzido em parceria entre o Ipea e o Fórum Brasileiro de Segurança Pública, é provavelmente o exemplo mais conhecido: trata-se de um relatório periódico que reúne indicadores de violência, especialmente homicídios, discutindo também as desigualdades territoriais do fenômeno e a qualidade dos dados disponíveis no país. Esse tipo de publicação mostra como é possível transformar dados brutos de segurança pública em análises que realmente dialogam com a sociedade.

O próprio Sinesp, por meio do seu painel público de estatísticas, também representa um esforço de disponibilizar e visualizar dados de segurança de forma mais acessível, ainda que de maneira mais tabular e menos voltada à análise espacial. Já o SIM/DATASUS, mantido pelo Ministério da Saúde, oferece uma perspectiva complementar e bastante utilizada em estudos nacionais sobre homicídios, já que registra óbitos por causas externas e agressões a partir de declarações de óbito, portanto, com origem e metodologia diferentes das bases policiais, mas que frequentemente é usada para validar ou comparar os números de segurança pública.

No campo acadêmico, é bastante comum encontrar trabalhos que aplicam técnicas de estatística espacial, como o próprio Índice de Moran e a estatística LISA, ao estudo da criminalidade em cidades ou regiões específicas do Brasil, geralmente utilizando ferramentas como GeoDa ou bibliotecas Python voltadas à análise espacial, como o PySAL. A criminalidade raramente se distribui de forma homogênea pelo espaço, tendendo a formar concentrações que só ficam evidentes quando se olha para o dado de forma espacial e não apenas tabular. É por esse motivo que este projeto busca contribuir, propondo uma integração entre as fontes de segurança pública, demografia e saúde, em apenas uma única aplicação de exploração espacial de fácil acesso.

6. Metodologia — visão geral

O projeto vem sendo conduzido de forma iterativa, organizado em sprints, seguindo uma lógica próxima da metodologia ágil e inspirada, em seus fundamentos, na Design Science Research Methodology, já que o produto final esperado é uma solução prática, uma aplicação de análise espacial, construída e avaliada ao longo de ciclos sucessivos de planejamento, desenvolvimento e revisão. Na Sprint 0, o trabalho concentrou-se na definição do escopo do projeto, na elaboração do Business Model Canvas e na escrita das primeiras histórias de usuário, além da estruturação do repositório no GitHub, onde código, dados e o próprio artigo científico passaram a ser versionados. Essa etapa, embora não envolva ainda manipulação de dados propriamente dita, foi fundamental para alinhar expectativas e organizar o backlog de funcionalidades a serem desenvolvidas nas sprints seguintes.

Na Sprint 1, o foco passou a ser efetivamente os dados. A fonte principal utilizada foi o Sinesp VDE, cujas planilhas anuais, de 2015 a 2026, trazem informações sobre unidade da federação, município, tipo de evento, data de referência, totais e abrangência da ocorrência. Nessa etapa, algumas decisões metodológicas precisaram ser tomadas: o campo evento passou a ser tratado como o indicador criminal de interesse; a data de referência foi utilizada para extrair o ano e o mês de cada registro; e, para lidar com a diferença entre contagem por vítima e por ocorrência, o campo `total_vitima` foi priorizado quando preenchido, recorrendo-se ao campo `total` como alternativa nos demais casos.

Para viabilizar a comparação proporcional entre estados, a população residente estimada por unidade da federação foi obtida junto ao SIDRA/IBGE, permitindo o cálculo da taxa de ocorrências por 100 mil habitantes. Já a dimensão espacial da análise foi construída a partir da

malha territorial digital das unidades da federação disponibilizada pelo IBGE, em sua versão de 2024, integrada aos dados criminais por meio da biblioteca GeoPandas, o que possibilitou a geração de mapas temáticos e, em uma etapa posterior, de um mapa interativo com detalhamento por estado.

Ao longo dessa análise exploratória, também foram identificados possíveis pontos fora do padrão a partir do intervalo interquartil, uma forma simples e amplamente utilizada de sinalizar valores que se destacam significativamente do restante da distribuição, o que, em dados de criminalidade, pode indicar tanto eventos atípicos quanto possíveis inconsistências no registro.

As próximas etapas do projeto, já mapeadas no backlog, incluem a aplicação de testes de autocorrelação espacial (Moran Global e LISA) para identificar clusters de criminalidade, a exploração de modelos de aprendizado de máquina para estimativa de risco por região e, por fim, a publicação de toda essa análise em uma aplicação web construída com Streamlit, hospedada de forma gratuita, para que o resultado do projeto não fique restrito a um notebook técnico, mas possa ser efetivamente consultado por gestores públicos, pesquisadores e demais interessados no tema.